MEMORIA EDA:
COMPARATIVA DE TELÉFONOS INTELIGENTES

Fecha: 11/11/2026

Contenido

1 Introducción 2

2 Hipótesis 2

3 Datos 2

4 Carga y exploración inicial de dataset 3

5 Preparación del dataset para el análisis 4

5.1 Registros con valores faltantes 4

5.2 Creación de nuevas características 4

6 Análisis del dataset 5

6.1 Análisis univariante 5

6.2 Análisis multivariante 7

7 Contraste de hipótesis 8

7.1 Hipótesis 1 8

7.2 Hipótesis 2 8

7.3 Hipótesis 3 9

8 Posibles trabajos futuros 9

1 Introducción

Con este EDA se trata de determinar las características más habituales de los teléfonos inteligentes y los factores que más influyen en su precio, en base a un dataset que incluye precios, valoraciones y datos técnicos de teléfonos de varias marcas.

Se pueden señalan las siguientes motivaciones para el estudio:

- Gran crecimiento del sector en la última década.
- Notable presencia del teléfono inteligente en nuestras vidas, como dispositivo multiuso que es: teléfono, navegador de internet, módem USB, visor y editor de documentos, cámara de vídeos y fotos, reproductor multimedia, billetera digital, GPS, lupa, reloj, afinador, sonómetro, nivel, brújula, despertador, linterna, agenda, calculadora, control remoto, …

2 Hipótesis

Se trata de contrastar las siguientes hipótesis:

1. Algunas características técnicas de los teléfonos influyen notablemente en su precio.
2. Hay un factor marca que también influye en el precio de los teléfonos.
3. Por encima del rango de precios medio, la mejora en prestaciones para un incremento de precio determinado tiende a ser menor que en precios más bajos.

3 Datos

Se utiliza un dataset procedente de la siguiente url:

https://www.kaggle.com/datasets/agarwalyashhh/smartphones-complete-data/data

Resumen del dataset (extraído de https://www.kaggle.com/code/msjahid/smartphone-insights-exploratory-data-analysis):

1. Brand Name: The name of the smartphone brand.
2. Model: The model name of the smartphone.
3. Price: The price of the smartphone.
4. Rating: The rating of the smartphone, typically based on user reviews or expert evaluations.
5. Has 5G: Indicates whether the smartphone has 5G connectivity capability.
6. Has NFC: Indicates whether the smartphone has Near Field Communication (NFC) technology.
7. Has IR Blaster: Indicates whether the smartphone has an Infrared (IR) blaster for remote control functionality.
8. Processor Brand: The brand of the processor used in the smartphone.
9. Num Cores: The number of cores in the smartphone processor.
10. Processor Speed: The speed of the smartphone processor.

11. Battery Capacity: The capacity of the smartphone battery, usually measured in milliampere-hours (mAh).
12. Fast Charging Available: Indicates whether the smartphone supports fast charging technology.
13. Fast Charging: Details about the fast charging capability, such as the type of fast charging technology.
14. RAM Capacity: The amount of Random Access Memory (RAM) in the smartphone, usually measured in gigabytes (GB).
15. Internal Memory: The internal storage capacity of the smartphone, usually measured in gigabytes (GB) or terabytes (TB).
16. Screen Size: The size of the smartphone screen, typically measured diagonally in inches.

Además del dataset indicado, se ha utilizado otro ubicado en la siguiente dirección:

https://www.kaggle.com/datasets/sumanbera19/phone-price-dataset/data

Este segundo dataset tiene mejor valoración de usabilidad en Kaggle que el anterior. Por otra parte, no está tan bien preparado para el análisis como el primero, ya que algunas de sus columnas contienen frases con más de un dato que sería necesario parsear. Por eso, el EDA se ha hecho con el primer dataset, y el segundo se ha utilizado únicamente para comparar algunos de los datos del primero. Con esta comparación, hecha en la hoja comp del Excel ./src/xls/ smartphones.xls, se ha comprobado que en los modelos de móviles incluidos en ambos datasets, los datos técnicos comparados son iguales en ambos datasets, y los precios muy similares.

Tanto este dataset como el anterior son del año 2023, y los datos de ambos son de la India.

4 Carga y exploración inicial de dataset

Como herramienta principal del análisis se ha usado Python (principalmente Pandas). También se ha usado Excel para chequeo, filtrado y graficado (ver Excel ./src/xls/ smartphones.xls).

El siguiente listado muestra la dimensión del dataset junto con las columnas y el tipo de datos de cada una.

```
#   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   brand_name                980 non-null    object
 1   model                     980 non-null    object
 2   price                     980 non-null    int64
 3   rating                    879 non-null    float64
 4   has_5g                    980 non-null    bool
 5   has_nfc                   980 non-null    bool
 6   has_ir_blaster            980 non-null    bool
 7   processor_brand           960 non-null    object
 8   num_cores                 974 non-null    float64
 9   processor_speed           938 non-null    float64
 10  battery_capacity          969 non-null    float64
 11  fast_charging_available   980 non-null    int64
 12  fast_charging             769 non-null    float64
 13  ram_capacity              980 non-null    float64
```

```
 14  internal_memory            980 non-null    float64
 15  screen_size                980 non-null    float64
 16  refresh_rate               980 non-null    int64
 17  num_rear_cameras           980 non-null    int64
 18  num_front_cameras          976 non-null    float64
 19  os                         966 non-null    object
...
 24  resolution_width           980 non-null    int64
 25  resolution_height          980 non-null    int64
```

10 de las 26 columnas del dataset contienen valores nulos, siendo en todos los casos valores faltantes. Las columnas con más valores faltantes son extended_upto, fast_charging y rating. La cantidad de valores faltantes en el resto de columnas es inferior al 5%.

En las columnas extended_upto y fast_charging, se espera que falten valores en los registros en los que su booleano relacionado (extended_memory_available y fast_charging_available, respectivamente) es 0.

Por otra parte, se ha chequeado que no hay registros duplicados en el dataset.

5 Preparación del dataset para el análisis

5.1 Registros con valores faltantes

Se ha optado eliminar los registros con valores nulos en alguna de las siguientes columnas: 'processor_brand', 'processor_speed', 'battery_capacity', 'os', 'primary_camera_front'. Con esto, se han eliminado 80 de los 980 registros del dataset. Los valores faltantes restantes tras este filtrado se han dejado así.

La marca de móviles más afectada por este filtrado es Apple, reduciéndose su número de registros de 46 antes del filtrado a 23 tras él. El precio medio de los modelos de Apple que han quedado tras este filtrado se ha reducido ligeramente con respecto al precio medio de los 46 registros iniciales.

5.2 Creación de nuevas características

Se han añadido dos nuevas columnas en el dataset:

- ‘precio_eur’: se considera que el dato de la columna ‘price’ está en rupias indias. En esta columna se da el cambio aproximado en euros. Teniendo en cuenta el rango en el que se movió el tipo de cambio en 2023, el cálculo se ha hecho como ‘precio_eur’ = ‘price’ / 90.

- ‘cat_precio’: en esta columna se ha asignado a cada registro una categoría, en función de su precio, para segmentar los registros en distintas gamas. Por lo tanto, la columna tiene datos de tipo categórico ordinal. Se han definido las siguientes categorías de precios: ['muy básico', 'básico', 'medio-básico', 'medio-alto', 'alto', 'muy alto', 'lujo']. Los precios en euros que marcan los límites entre las distintas categorías son los siguientes:

  [0, 60, 120, 220, 450, 800, 2000, max]

Y sus correspondientes percentiles en este dataset resultan ser, en tanto por ciento:

[0.0, 0.9, 15.6, 50.0, 81.8, 92.8, 99.6, 100.0]

Para parte del EDA se han agrupado como sigue las categorías de precios indicadas anteriormente:

- Gama básica: ['básico']
- Gama media: ['medio-básico', 'medio-alto']
- Gama alta: ['alto', 'muy alto']

Además, se han descartado las categorías más extremas (‘muy básico’ y ‘lujo’), conteniendo entre ambas aproximadamente el 1.5% de los registros del dataset filtrado. Esto se ha hecho para evitar que los valores atípicos de estos registros distorsionen el análisis. Por ejemplo, los dos modelos más caros del dataset tienen unos precios por encima de los 7000 y 5000 euros respectivamente, muy por encima del resto. El precio de estos dos modelos se explica porque incluyen materiales preciosos en sus carcasas.

6 Análisis del dataset

6.1 Análisis univariante

Además de la información obtenida con la función describe() de DataFrames de Pandas, se ha analizado la distribución de los datos de cada columna con distintos tipos de gráficos. Se han realizado histogramas, box-plots y violin-plots para las variables numéricas, y gráficos de barras para las variables categóricas y booleanas. Esto ha servido para ver las características más habituales de los teléfonos inteligentes del dataset. En este análisis se ha aprovechado la variable de segmentación definida en la columna ‘cat_precio’ (ver apartado 5.2), para ver también las tendencias de cada variable con el precio.

Estas son algunas de las observaciones que se desprenden de este análisis:

- Las valoraciones dadas a los modelos se concentran en el intervalo 75-85. La valoración dada a los modelos crece con el precio hasta la gama de precio alta, estabilizándose e incluso decreciendo posteriormente en las gamas muy alta y de lujo.
- La gran mayoría de modelos tienen procesadores con 8 núcleos.
- La velocidad de los procesadores tiende a crecer con el precio hasta la gama de precios alta.
- La capacidad de la batería de los modelos se concentra en torno a 5000 mAh. No cambia significativamente en una amplia gama de precios, y es menor en la gama de lujo y sobre todo en la gama muy básica.
- La potencia de carga rápida tiende a crecer desde la gama de precios básica hasta la alta.
- La capacidad de RAM tiende a crecer con el precio hasta la gama de precios alta.
- La capacidad de almacenamiento tiende a crecer con el precio.
- El tamaño de pantalla tiende a crecer con el precio hasta la gama de lujo, observándose la diferencia más notable entre la gama muy básica y el resto de gamas.

- La frecuencia de refresco tiende a ser más alta con el precio, hasta la gama de precios alta.
- Nº de cámaras traseras: lo más típico en los modelos de gama básica es que tengan 1 ó 2 cámaras traseras. En los de gama media y alta, 3.
- Las resoluciones de las cámaras de los modelos de gama básica son inferiores a las de los modelos de las gamas medias y altas.
- La resolución de pantalla tiende a crecer con el precio.
- Estas son algunas de las variables numéricas en las que se observa una correlación más clara con el precio:
    - rating
    - processor_speed
    - fast_charging
    - ram_capacity
    - internal_memory
    - refresh_rate
    - num_rear_cameras
    - primary_camera_rear
    - resolution_width
- La mayoría de modelos del dataset se concentra en la gama de precios media. Como excepción, la mayor parte de los modelos de Apple están en la gama de precios muy alta. También hay bastantes modelos de Samsung en la gama de precios muy alta, aunque menos que en las gamas medias.
- Las marcas de procesadores dominantes son snapdragon, helio y dimensity. Los de los Apple son bionic, con 6 núcleos frente a los 8 núcleos de la mayoría del resto de modelos.
- La inmensa mayoría de los modelos tiene sistema operativo Android. El de los Apple es ios.
- 5G:
    - La cantidad de modelos con 5G en el dataset es ligeramente superior a la cantidad sin 5G.
    - La proporción de modelos con 5G crece en gamas de precios más altas.
- NFC:
    - Hay bastantes más modelos sin NFC que con NFC.
    - La proporción de modelos con NFC crece en gamas de precios más altas. Casi ningún modelo de los rangos de precio menores tiene NFC, y casi todos los de las gamas de precios más altas tiene NFC.
- Pocos modelos tienen puntero IR en todas las gamas, encontrándose sobre todo en la gama media.
- La gran mayoría de modelos del dataset tiene capacidad de carga rápida. Solo en las gamas más básicas hay una proporción no muy baja de modelos sin carga rápida.
- Hay bastantes más modelos con capacidad de extensión de memoria que sin ella, encontrándose sobre todo en las gamas media y baja (en las que la capacidad de almacenamiento de serie es menor).

Se resume a continuación el perfil central de los modelos de este dataset. Los datos numéricos son rangos intercuartílicos.

- Marcas con más modelos: Xiaomi, Samsung, Vivo y Realme.
- RAM: 4-8 GB.
- Memoria interna: 64–128 GB.
- Procesador: 2.05–2.84 GHz y normalmente 8 núcleos.
- Batería: 4500–5000 mAh.
- Resolución de cámara trasera principal: 24–64 MP.
- Precio: 144–394 €.

6.2 Análisis multivariante

Se han hecho los siguientes análisis, para distintas gamas de precios:

- Cálculo de matrices de correlación con el método de Spearman disponible en Pandas.
- Pairplots de variables numéricas.
- ANOVAs del precio de los modelos con las siguientes variables booleanas: has_5g, has_nfc, has_ir_blaster, fast_charging_available y extended_memory_available. Se resumen a continuación las observaciones de estos análisis, en los que se ha considerado un α de 0.05:
    - En la gama de precios baja, se puede afirmar que se correlacionan con el precio las variables booleanas has_ir_blaster y fast_charging_available, siendo más caros los modelos con las variables igual a True.
    - En la gama de precios media, se puede afirmar que se correlacionan con el precio las variables booleanas has_5g, has_nfc, fast_charging_available y extended_memory_available. Tienden a ser más caros los modelos con las variables has_5g, has_nfc y fast_charging_available igual a True y con la variable extended_memory_available igual a False.

      La correlación negativa de la disponibilidad de extensión de memoria con el precio puede deberse a que los modelos con precios más altos prescinden de esa capacidad por tener de inicio mayor capacidad de almacenamiento. En el cálculo de matrices de correlación también se observó correlación negativa de la disponibilidad de extensión de memoria con algunas características técnicas y con el precio, sobre todo en esta gama de precios.
    - En la gama de precios alta no se observa una correlación significativa entre ninguna de estas variables booleanas y el precio.
- ANOVAs y test de Tukey para ver si hay diferencias significativas de precio entre distintas marcas de móviles. Para este análisis se han seleccionado las siguientes marcas, ordenadas por precio medio de la más cara a la más barata: Apple, Samsung, Xiaomi y Realme. Apple se ha seleccionado por presentar diferencias significativas de precio con respecto a las demás, y las otras tres porque también presentan diferencias significativas de precio entre ellas, y porque además son de las que más registros tienen en el dataset (Xiaomi y Samsung las dos que más, y Realme la cuarta).

  Estos ANOVAs indican que hay diferencias significativas de precios entre los conjuntos de modelos incluidos en el dataset de las marcas Apple, Samsung, Xiaomi y Realme. Esto no significa que haya influencia del factor marca en los precios, ya que las

características técnicas de los distintos conjuntos comparados también podrían ser significativamente diferentes. Ver apartado 7.2.

Se puede decir lo mismo del test de Tukey, salvo que no confirma diferencia significativa de precios entre las marcas Xiaomi y Realme.

7 Contraste de hipótesis

7.1 Hipótesis 1

Hipótesis 1: Algunas características técnicas de los teléfonos influyen notablemente en su precio.

Valoración: Confirmada.

Los análisis expuestos en el apartado 6 muestran correlación entre varias de las características técnicas incluidas en el dataset y el precio de los modelos. Esto se confirma también con gráficos de dispersión entre el precio y las características técnicas. Se ha observado también que muchas de las variables que se correlacionan positivamente con el precio también lo hacen con el rating, y que hay una fuerte correlación del precio con el rating.

Estas son las características técnicas en las que se observa una correlación más clara con el precio: ram_capacity, processor_speed, internal_memory, has_nfc y has_5g.

7.2 Hipótesis 2

Hipótesis 2: Hay un factor marca que también influye en el precio de los teléfonos.

Valoración: “Confirmada con dudas.”

Se han realizado gráficos de dispersión del precio con respecto a distintas características técnicas, distinguiendo los modelos de las marcas seleccionadas en el apartado 6.2 (Apple, Samsung, Xiaomi y Realme). En algunas de las características técnicas, estos gráficos muestran el mismo orden de estas marcas en precio que el indicado en el apartado 6.2 (salvo en el rango más bajo de precios, donde Samsung, Xiaomi y Realme parecen bastante parejos en precio), pero esto no ha podido observar con todas las características técnicas.

Otro análisis que se ha llevado a cabo para tratar de confirmar esta hipótesis ha sido comparar modelos seleccionados de distintas gamas de estas 4 marcas, procurando en cada caso que las características técnicas de todos sean similares para “comparar manzanas con manzanas” en la medida de lo posible. Tras algunos intentos para hacer esta selección programáticamente, se ha terminado haciendo manualmente. En esta selección se han descartado los modelos que contienen la palabra 'fold', ‘flip’ o ‘duo’ dentro del nombre del modelo (hay 10 con la palabra ‘fold’, 5 con la palabra ‘flip’ y ninguno con la palabra ‘duo’ en todo el dataset), considerando que son modelos con pantalla plegable, que tienen un coste considerablemente superior a los modelos con pantalla rígida.

Este análisis parece confirmar la hipótesis 2, ya que se ha observado el mismo orden de precios en las marcas seleccionadas que el observado en análisis anteriores. Sin embargo, se considera que no es suficiente para poder contrastar esta hipótesis, porque el análisis se basa en observaciones puntuales que pueden estar sujetas a dispersión, y además hay algunas diferencias en las características técnicas de los modelos comparados en cada caso.

Sería necesario un análisis más detallado para contrastar de forma más rigurosa esta hipótesis. Sería de utilidad ajustar un modelo para predecir los precios en función de las características técnicas y de la marca.

7.3 Hipótesis 3

Hipótesis 3: Por encima del rango de precios medio, la mejora en prestaciones para un incremento de precio determinado tiende a ser menor que en precios más bajos.

Valoración: “Confirmada con dudas.”

No se ha podido comprobar que se cumpla esta hipótesis de forma generalizada, pero se han observado algunos indicios que apuntan a su confirmación:

- En el análisis univariante segmentado por categorías de precios expuesto en el apartado 6.1, se aprecia un estancamiento en algunas características técnicas (como processor_speed, ram_capacity, refresh_rate, primary_camera_rear y primary_camera_front) con el precio a partir de la categoría de precios 'alto' o 'medio-alto'.

- En el análisis en base a gráficos de dispersión expuesto en el apartado 7.2, se aprecia que la sensibilidad del precio a la RAM es mayor en precios altos en los Xiaomi y sobre todo en los Samsung. Pero no se puede confirmar que esto se cumpla con otras características técnicas o en otras marcas.

- El rating, que tiene una fuerte correlación (no lineal) con el precio, y que, como el precio, se correlaciona positivamente con varias características técnicas, como se indicó en el apartado 7.1, tiene una sensibilidad considerablemente menor al precio en precios más altos. Si se considera que los datos de rating del dataset analizado son una buena medida del nivel de prestaciones/calidad de los productos, esta observación vendría a respaldar la hipótesis 3. Pero la relación entre rating y precio también podría deberse a cómo perciben o valoran los consumidores distintos niveles de calidad de los teléfonos (por quedar sus expectativas suficientemente cubiertas con un determinado nivel de prestaciones).

Con todo lo expuesto, se considera que se requiere un análisis más detallado para contrastar esta hipótesis. Una idea sería ajustar regresiones lineales para distintas gamas de precios, y revisar si las sensibilidades o las elasticidades del precio frente a las distintas características técnicas son mayores en gamas de precios más altas.

8 Posibles trabajos futuros

Se señalan los siguientes posibles trabajos futuros:

- Ajustar un modelo de ML para predecir precios y rating de los teléfonos inteligentes, en función de sus características técnicas y marca. Esto podría ayudar a responder de forma más completa las hipótesis planteadas, y a valorar si sería necesario incorporar datos de otras características técnicas en el análisis (por ejemplo, zoom óptico de las cámaras).

- Hacer un análisis de mercado, para tratar de identificar qué factores ayudan a incrementar las ventas o ingresos, y hasta qué punto estos se correlacionan con el rating.
- Estudiar la evolución a lo largo del tiempo de las características técnicas y precios de los móviles.
- Estudiar datos de otras regiones del mundo. Esto puede ser de interés porque los precios de distintos fabricantes pueden variar sustancialmente entre distintas regiones, por lo que las conclusiones obtenidas con datos de una región pueden no ser extrapolables a otras, especialmente en lo relativo a comparativas de precios entre distintas marcas. Los datos utilizados en el presente análisis son de la India, como se ha indicado en el apartado 3.